

UNIVERSIDAD
DE MURCIA

Proyecto Final EML Bloque II

Optimización de Carteras Multiactivo mediante

Aprendizaje por Refuerzo Personalizado

Extensiones de Machine Learning

Curso 2025/2026

Facultad de Informática

Grado en Ciencia e Ingeniería de Datos

Javier Hernández Rosique

Álvaro Espejo Martínez



1. Introducción y Motivación.....	2
2. Estado del Arte.....	3
De la Teoría de Carteras a la Gestión Dinámica.....	3
Evolución de Algoritmos: De SARSA a Deep RL.....	4
Optimización Multiobjetivo y Perfilado de Riesgo.....	4
3. Objetivos.....	5
Formalización del problema de inversión como un proceso de decisión de Markov (MDP).....	5
Desarrollo de una función de recompensa multi-objetivo.....	5
Ejecución de una metodología de desarrollo incremental.....	5
Evaluación comparativa.....	5
4. Descripción del Dataset y Preprocesamiento.....	7
Análisis Exploratorio y Validación Estadística.....	7
Ingeniería de Variables.....	11
Control de Data Leakage y División Temporal.....	12
5. Desarrollo Técnico Inicial.....	13
5.1. Diseño del Entorno de Simulación.....	13
5.2. SARSA V1: El Prototipo de Validación.....	16
Análisis de Resultados.....	17
5.3 SARSA V2. Hacia el Realismo Operativo.....	19
Análisis de Resultados.....	20
6. Deep Q-Network. Potenciamiento con Redes Neuronales.....	22
6.1. Arquitectura de Deep Reinforcement Learning.....	22
6.2. Estrategias de Estabilización y Entrenamiento.....	23
6.3. Función de Recompensa.....	24
6.4. Análisis de Resultados y Discusión.....	26
Metodología de Evaluación y Rigor de las Pruebas.....	26
Comportamiento y Diferenciación por Perfiles de Usuario.....	26
Justificación de Resultados y Comparativa Final.....	30
7. Conclusiones y Vías Futuras.....	32
7.1. Vías Futuras: Integración de Sensores y NLP.....	32
Propuesta Técnica.....	33
8. Bibliografía.....	34

1. Introducción y Motivación

El campo de la gestión de carteras financieras se enfrenta a una complejidad intrínseca difícilmente comparable a otros campos de análisis, marcada por la naturaleza no estacionaria de los mercados y la volatilidad inherente a los activos globales. Tradicionalmente, la toma de decisiones se ha basado en heurísticas de reglas fijas o en modelos puramente supervisados; sin embargo, estos enfoques a menudo presentan dificultades para capturar la dinámica secuencial y el carácter adaptativo que exige una inversión verdaderamente autónoma. En la práctica, un inversor no solo debe discernir entre la compra o venta de un activo específico, sino que debe gestionar activamente el riesgo de caídas severas, determinar los periodos óptimos de permanencia en liquidez y equilibrar constantemente la rentabilidad esperada frente a la exposición y volatilidad del mercado.

La motivación central de este proyecto reside en superar estas limitaciones mediante el paradigma del Aprendizaje por Refuerzo (*Reinforcement Learning*). Este enfoque nos permite modelar el problema de inversión como una interacción continua entre un agente y un entorno financiero dinámico, donde el agente observa el estado del mercado, ejecuta acciones y recibe una recompensa basada en la evolución de su capital. No buscamos simplemente una solución genérica que intente "batir a la bolsa" en términos absolutos, sino una arquitectura capaz de procesar datos históricos bajo restricciones realistas para aprender una política de inversión razonable, coherente y, sobre todo, robusta ante diferentes regímenes de mercado.

Un factor diferenciador clave en nuestro desarrollo es la integración de la adaptabilidad al perfil del inversor. Reconocemos que el éxito de una estrategia no debe medirse únicamente por el beneficio neto, sino por su alineación con parámetros críticos definidos por el usuario, tales como la tolerancia al riesgo y el horizonte temporal. Al dotar al agente de la capacidad de interpretar el estado de su portafolio junto a indicadores de mercado y preferencias de usuario, transformamos la gestión de activos —incluyendo renta variable como el SPY y QQQ, y activos de refugio como el oro (GLD) o bonos (TLT)— en un sistema de decisión inteligente que "gana dinero de la forma en que el usuario lo ha solicitado".

2. Estado del Arte

Históricamente, la gestión de carteras y la toma de decisiones en los mercados financieros se han basado en dos pilares: el análisis técnico y las estrategias de gestión pasiva. Las estrategias de "reglas fijas", fundamentadas en indicadores técnicos o modelos puramente supervisados, han sido el estándar durante décadas. Sin embargo, estos enfoques presentan una limitación estructural: su dificultad para capturar la naturaleza secuencial de las decisiones y la retroalimentación constante del entorno. Mientras que el aprendizaje supervisado intenta predecir una dirección (subida o bajada), a menudo ignora las consecuencias a largo plazo de una acción, como el impacto de los costes de transacción acumulados o la gestión dinámica del capital.

En este contexto, la estrategia de **Buy & Hold** (comprar y mantener), particularmente sobre el índice S&P 500 (representado por el ETF SPY), se ha consolidado como el *benchmark* o punto de referencia absoluto en la industria. A pesar de su simplicidad, históricamente es una de las estrategias más difíciles de batir de manera consistente, especialmente cuando se ajusta por riesgo y volatilidad. La literatura financiera reciente ha demostrado que, aunque el mercado tiene una tendencia alcista secular, los periodos de crisis y los cambios de régimen económico exigen una gestión más activa para proteger el capital y reducir el *drawdown* máximo.

Actualmente, la investigación en inversión automatizada no solo busca la maximización del retorno, sino la personalización del riesgo. El uso de activos diversificados que cubren diferentes clases de inversión —como renta variable tecnológica (QQQ), bonos del Tesoro (TLT) y oro (GLD)— junto con el procesamiento de "sensores de entorno" como el índice de volatilidad ($\sqrt{VIX}$), permite a los agentes modernos emular la diversificación que tradicionalmente realizaban gestores humanos, pero con la capacidad de reaccionar a la velocidad de los datos.

De la Teoría de Carteras a la Gestión Dinámica

La base de la optimización de carteras se remonta a la **Teoría Moderna de Carteras (MPT)** de Markowitz (1952), la cual establece el equilibrio estático entre riesgo y retorno. Sin embargo, la literatura reciente señala que los modelos clásicos como el CAPM o la MPT fallan al capturar la naturaleza no lineal y altamente dinámica de los mercados actuales. Frente a esto, el **Aprendizaje por Refuerzo (RL)** ha emergido como un paradigma superior al permitir que un agente aprenda políticas de asignación de activos mediante la interacción continua con el entorno, modelando el problema como un Proceso de Decisión de Markov (MDP).

Evolución de Algoritmos: De SARSA a Deep RL

En el ámbito del trading algorítmico, el uso de métodos de diferencia temporal (*Temporal Difference*) ha sido fundamental. Algoritmos "on-policy" como **SARSA** han demostrado ser herramientas robustas para validar políticas en espacios de estados discretos, permitiendo al agente aprender patrones intuitivos de mercado. No obstante, la investigación actual subraya que para manejar carteras multiactivo complejas y vectores de estado ricos (indicadores técnicos y sensores macroeconómicos), es necesaria la transición hacia el **Deep Reinforcement Learning (DRL)**.

El uso de **Deep Q-Networks (DQN)**, como el implementado en la fase avanzada de este proyecto, permite superar la "maldición de la dimensionalidad" mediante el uso de redes neuronales profundas que aproximan la función de valor $Q(s, a)$. Estudios recientes (2024-2025) confirman que las arquitecturas **DQN** y sus variantes (como **Double DQN**) superan consistentemente a las estrategias de **Buy & Hold** y a los modelos de varianza mínima en términos de *Ratio de Sharpe*(1) y reducción del *Drawdown* (2) máximo.

Optimización Multiobjetivo y Perfilado de Riesgo

Una tendencia crítica en la literatura de 2025 es la integración de la **aversión al riesgo** directamente en la función de recompensa. Mientras que los modelos de RL tempranos se centraban exclusivamente en maximizar el retorno acumulado, los marcos de trabajo modernos emplean técnicas de **escalarización** para equilibrar múltiples objetivos: maximización de beneficios, minimización de volatilidad y promoción de la diversificación. Este enfoque multiobjetivo permite personalizar la política del agente según el perfil del inversor, transformando la gestión de activos en un sistema de decisión contextualmente consciente que protege el capital en regímenes de mercado adversos.

(1) **Ratio De Sharpe:** Es una métrica que cuantifica la eficiencia de una inversión al medir el exceso de rentabilidad obtenido por cada unidad de riesgo (volatilidad) asumida. Matemáticamente, se expresa como: (R_p : Retorno de Cartera, R_f : tasa libre de riesgo, σ_p : desviación estándar de los retornos.)

$$S = \frac{R_p - R_f}{\sigma_p}$$

(2)**Drawdown:** Caída porcentual acumulada desde un máximo histórico hasta su punto más bajo antes de un nuevo máximo.

3. Objetivos

El **objetivo general** de este trabajo es el diseño y la implementación de un agente de inversión autónomo basado en el paradigma de Aprendizaje por Refuerzo (RL), capaz de operar en mercados financieros dinámicos y de adaptar su política de ejecución a las preferencias específicas de riesgo y horizontes temporales del usuario final. A diferencia de los enfoques de optimización convencionales, este proyecto busca desarrollar un sistema que no solo persiga la maximización del beneficio neto, sino que logre una gestión de activos contextualmente consciente, integrando la aversión al riesgo del inversor como una variable fundamental en la toma de decisiones secuenciales.

Para alcanzar esta meta, se han señalado distintas metas a lo largo de la realización:

Formalización del problema de inversión como un proceso de decisión de Markov (MDP).

Bajo la interfaz estándar de Gymnasium, implica definir un vector de estado complejo que sintetice indicadores técnicos, el estado actual de la cartera y el perfil del usuario, así como un espacio de acciones discreto que permita rebalanceos periódicos del capital.

Desarrollo de una función de recompensa multi-objetivo

Estrechamente ligado al MDP tratado previamente, se plantea una función de recompensa que sea capaz de penalizar la volatilidad(3) y los drawdowns de manera proporcional a la configuración del inversor, incentivando políticas de inversión que protejan el capital en mercados inciertos.

Ejecución de una metodología de desarrollo incremental

Un tercer objetivo central rodea la hipótesis de viabilidad de la formulación propuesta. Se inicia con el despliegue de agentes de aprendizaje por diferencia temporal, específicamente mediante el algoritmo **SARSA** tabular, para establecer un *baseline* sólido y transparente en entornos controlados de un solo activo. Posteriormente, se busca escalar esta solución hacia una arquitectura de *Deep Q-Network (DQN)*, sustituyendo la tabla de valores Q por un aproximador de función no lineal que permita al agente generalizar su aprendizaje en un universo multiactivo compuesto por renta variable, bonos y metales preciosos.

Evaluación comparativa

Finalmente, el proyecto plantea una comparación analítica rigurosa bajo condiciones de *backtesting* fuera de la muestra (*out-of-sample*).

El comportamiento de los agentes será contrastado frente a la estrategia pasiva de referencia *Buy & Hold* del índice *S&P 500*, analizando métricas financieras críticas como el *Sharpe Ratio*, la volatilidad anualizada y el *drawdown* máximo. Esta fase de análisis permitirá no solo

verificar el rendimiento del modelo, sino también reflexionar críticamente sobre la capacidad real del Aprendizaje por Refuerzo para capturar patrones de valor en datos financieros históricos.

4. Descripción del Dataset y Preprocesamiento

Para garantizar la fidelidad y reproducibilidad del entorno de simulación, se han utilizado series temporales financieras obtenidas mediante la API pública de *yfinance*. El conjunto de datos abarca un horizonte temporal que va desde el año 2010 hasta principios de 2025, proporcionando una muestra rica en diversos ciclos económicos, incluyendo periodos de expansión secular y crisis de volatilidad extrema. La arquitectura de datos se ha dividido en dos categorías funcionales: activos comerciables y sensores de entorno. Los primeros comprenden el ETF SPY (*S&P 500*) y QQQ (*Nasdaq 100*) para capturar el crecimiento de renta variable, junto con el TLT (*Bonos del Tesoro*) y GLD (*Oro*) como instrumentos de cobertura y refugio. Por otro lado, se han integrado sensores no operables como el índice de volatilidad (VIX) y la tasa de bonos a 10 años (TNX), que actúan como indicadores macroeconómicos de "miedo" y tipos de interés, que permitiría al agente contextualizar en función de la situación actual.

Cabe destacar, que pese al análisis realizado de manera preliminar en el análisis exploratorio de datos que se presenta, estas variables en forma de índices y sensores no han sido incluidas en las propuestas algorítmicas finales, pues su implementación abordaba el Procesamiento de Lenguaje Natural para la ingesta del modelo, lo que presentaba una complejidad suficiente para otro proyecto en sí. Se comentará en *vías futuras*.

Análisis Exploratorio y Validación Estadística


Se presentan los activos comerciales:

- SPY (*S&P 500*): Mercado de acciones general.
- QQQ (*Nasdaq 100*): Sector de crecimiento y tecnología
- TLT (*Bonos del Tesoro*): Activo de refugios
- GLD (*Oro*): Activo de refugio (materias primas).

El análisis estadístico previo reveló que el uso de precios brutos no es óptimo para el entrenamiento de modelos de aprendizaje automático debido a su naturaleza no estacionaria. En su lugar, se ha procedido al cálculo de **log-rendimientos diarios**, los cuales ofrecen una distribución más cercana a la normalidad y facilitan la convergencia algorítmica.

Una primera exploración se centrará en los valores nulos, que se explican por diferencias en festivos bursátiles en distintos activos. Para el posterior entrenamiento, estos nulos se tratarán rellenándolos con el último valor válido para asegurar su continuidad.

Será útil observar la naturaleza de estos activos a lo largo del recorrido histórico del dataset para entender el porqué de la dificultad de “batir” a la estrategia de *Buy & Hold*.



Podemos apreciar la tendencia alcista del mercado desde el inicio de la visualización hasta prácticamente a fecha actual.

Posteriormente, se dispone un análisis de estadísticas descriptivas de los retornos diarios, lo que nos permitirá profundizar de forma superficial en el comportamiento del mercado antes de encontrar insights más complejos.

```

--- Estadísticas Descriptivas de RETORNOS DIARIOS ---

```

Ticker	CL=F	DX=F	GLD	QQQ	SPY \
count	3997.000000	3997.000000	3997.000000	3997.000000	3997.000000
mean	-0.000683	0.000071	0.000358	0.000729	0.000505
std	0.058310	0.004569	0.009949	0.013023	0.010895
min	-3.059661	-0.023855	-0.087808	-0.119788	-0.109424
25%	-0.011712	-0.002580	-0.004799	-0.004739	-0.003777
50%	0.000821	0.000063	0.000508	0.001145	0.000643
75%	0.012301	0.002671	0.005598	0.007298	0.005762
max	0.376623	0.021887	0.049038	0.120031	0.105019


Ticker	TLT	^TNX	^VIX
count	3997.000000	3997.000000	3997.000000
mean	0.000043	0.000405	0.003155
std	0.009544	0.028025	0.082992
min	-0.066683	-0.293201	-0.357539
25%	-0.005782	-0.012905	-0.041901
50%	0.000448	0.000000	-0.006503
75%	0.005709	0.012801	0.035294
max	0.075196	0.498998	1.155979

Interesante es apreciar el estadístico descriptivo más básico, la media (retorno diario promedio a lo largo de los años). Como se esperaba, es un número muy pequeño, cercano a cero, pero generalmente positivo para los activos de crecimiento (*SPY*, *QQQ*).

Pasando a la desviación típica es donde observaremos la primera gran “pista” a tener en cuenta. Es la definición estadística de la **volatilidad** (riesgo). A simple vista, vemos que *QQQ* tiene un *std* más alto que *SPY*, confirmando que es más volátil. Por el contrario, *TLT* y *GLD* muestran un *std* más bajo, validando su rol como activos más estables.


Finalmente, atenderemos a los distintos cuantiles, donde los valores de *min* y *max* darán información sobre los días de pánico y euforia extremos, lo que son eventos de cola.

En entornos financieros de análisis, la **Moda** no atiende a un valor único, sino a un rango que apreciamos con un histograma.




El pico central o rango modal es el esperable, cercano a cero para los retornos diarios (*SPY*), ya que un día “normal” en el mercado presenta poca variabilidad. Sin embargo, la forma de la campana desvela más información que la mencionada. Las colas pesadas (**Leptocurtosis**) nos revelan que, aunque de un día para otro no se espera mucho cambio, los valores extremos son más frecuentes de lo que un modelo estadístico simple podría llegar a predecir. Esto justifica la necesidad de un agente robusto que gestione estos eventos.

Estas mismas conclusiones previas se pueden confirmar analizando los **Box-plots** de los activos.



De nuevo, confirmamos como *QQQ* es el más volátil de los cuatro, o que *GLD* es significativamente más estable (caja más pequeña), lo que será tenido en cuenta en el futuro por el modelo para calibrar según las características pre-establecidas. Así mismo, la gran cantidad de datos atípicos refuerza lo confirmado en el histograma; el agente debe aprender a gestionar los movimientos extremos.

Como observación final del EDA, visualizamos la **matriz de correlación**.



Esta contiene a los sensores previamente mencionados. Aunque se han descartado por el momento, no deja de ser interesante observar de qué manera interactúan con nuestros activos.

Centrándonos en estos, destacamos la alta correlación positiva *SPY-QQQ*, esperada en cierta manera por la naturaleza de ambas (ambas son acciones de EE.UU). De la misma manera, notamos la correlación negativa entre *SPY-TLT*, validando *TLT* como activo de refugio. Centrándonos en el oro (*GLD*), la baja correlación tanto con acciones como bonos valida su rol de diversificador y expone su naturaleza de resistencia contra la inflación.

Ingeniería de Variables

Para la construcción del vector de estado, se han calculado indicadores de momento y tendencia, destacando la Media Móvil Simple de 200 sesiones (SMA200) para identificar la tendencia primaria de largo plazo y el Índice de Fuerza Relativa (RSI) de 14 sesiones para medir condiciones de sobrecompra o sobreventa. Estos indicadores se han normalizado y, en

el caso de los modelos SARSA, se han discretizado en "cajas" o estados específicos para evitar la explosión del espacio de búsqueda en la tabla Q.

Control de Data Leakage y División Temporal

Dada la naturaleza secuencial de los datos financieros, se ha evitado estrictamente cualquier tipo de aleatorización en la división del dataset que pudiera comprometer la integridad de la evaluación. Se ha implementado un *split* temporal sólido (80/20), destinando el periodo 2010-2021 para el entrenamiento y el tramo 2022-2025 para el testeo *out-of-sample*. Para blindar el modelo contra el *data leakage*, se han incorporado comprobaciones por código que aseguran que la última fecha del conjunto de entrenamiento sea estrictamente anterior a la primera del conjunto de prueba, garantizando así que el agente sea evaluado en un entorno de "datos desconocidos" que simula condiciones reales de mercado.

5. Desarrollo Técnico Inicial

Esta sección constituye el núcleo de la fase de validación técnica del proyecto, donde se documenta la transición desde una prueba de concepto simplificada hasta un entorno de simulación con rigor operativo. El objetivo primordial de utilizar el algoritmo SARSA (*State-Action-Reward-State-Action*) en su variante tabular es establecer una línea base de rendimiento totalmente interpretable antes de abordar la complejidad de las redes neuronales profundas. Al trabajar con un espacio de estados reducido, podemos auditar directamente qué patrones de mercado está capturando el agente y verificar si la formulación de la recompensa incentiva comportamientos financieros racionales.

El verificar la idea inicial con un modelo base que implemente simplemente una abstracción de alto nivel del resultado final permite confirmar la viabilidad de nuestra hipótesis junto a los datos de los que disponemos, para así avanzar hacia una solución reforzada por la experiencia y el conocimiento que obtenemos de esta manera.

5.1. Diseño del Entorno de Simulación

El diseño del entorno financiero para agentes tabulares exige una simplificación estratégica para evitar la explosión de la dimensionalidad. Nos hemos basado en la interfaz estándar de Gymnasium. Se ha optado por una discretización del espacio de estados basada en tres pilares fundamentales que sintetizan la información técnica necesaria para la toma de decisiones: la tendencia de largo plazo, el momento del activo y la exposición actual de la cartera. La tendencia se determina mediante el cruce del precio de cierre con la Media Móvil Simple de 200 sesiones (SMA200), categorizando el mercado en alcista o bajista. El momento se captura a través de tres zonas del RSI de 14 sesiones:

- sobreventa ($RSI < 30$)
- zona neutral
- sobrecompra ($RSI > 70$).

Combinando estos indicadores con la posición binaria del agente (dentro o fuera del mercado), se obtiene un espacio de tan sólo 12 estados posibles, lo que garantiza una convergencia rápida y estable de la tabla Q.

La señal de aprendizaje o función de recompensa ha sido modelada para reflejar fielmente la rentabilidad económica de las decisiones tomadas. En lugar de utilizar una señal binaria de acierto o error, se ha definido la recompensa como el retorno simple de la cartera entre dos pasos temporales consecutivos: $r_t = (V_{t+1}/V_t) - 1$, donde V representa el valor total del capital. Esta formulación permite que el agente reciba una retroalimentación proporcional a la magnitud de los movimientos del mercado cuando está invertido, mientras que la recompensa es nula (o ligeramente negativa si existen costes) cuando permanece en liquidez. De este

modo, el agente no solo aprende a identificar la dirección del precio, sino también a valorar la importancia de la estabilidad del capital en regímenes de alta volatilidad.

Presentamos una tabla comparativa para visualizar la tabla de discretización de estados con la que opera el entorno de simulación de forma inicial:

Estado ID	Tendencia	Zona RSI	Posición Actual	Descripción
1	0 (Bajista)	0 (Sobreventa)	0 (Cash)	Mercado bajista, activo barato, agente fuera.
2	0 (Bajista)	0 (Sobreventa)	1 (Largo)	Mercado bajista, activo barato, agente invertido.
3	0 (Bajista)	1 (Neutral)	0 (Cash)	Mercado bajista, zona media, agente fuera
4	0 (Bajista)	1 (Neutral)	1 (Largo)	Mercado bajista, zona media, agente invertido.
5	0 (Bajista)	2 (Sobrecompra)	0 (Cash)	Mercado bajista, activo caro, agente fuera.
6	1 (Alcista)	2 (Sobrecompra)	1 (Largo)	Mercado bajista, activo caro, agente invertido.
7	1 (Alcista)	0 (Sobreventa)	0 (Cash)	Mercado alcista, corrección fuerte, agente fuera.
8	1 (Alcista)	0 (Sobreventa)	1 (Largo)	Mercado alcista, corrección fuerte, agente invertido.
9	1 (Alcista)	1 (Neutral)	0 (Cash)	Mercado alcista, tendencia sana, agente fuera.

10	1 (Alcista)	1 (Neutral)	1 (Largo)	Mercado alcista, tendencia sana, agente invertido.
11	1 (Alcista)	2 (Sobrecompra)	0 (Cash)	Mercado alcista, posible techo, agente fuera.
12	1 (Alcista)	2 (Sobrecompra)	1 (Largo)	Mercado alcista, posible techo, agente invertido.

De esta forma, operamos de una manera sencilla para pasar al modelo base.

5.2. SARSA V1: El Prototipo de Validación

En la primera iteración, denominada SARSA V1, el agente operó bajo un marco puramente teórico concebido como una prueba de concepto inicial. En esta versión, se ignoraron deliberadamente los costes de transacción y se restringió el espacio de acciones a una decisión binaria de entrar o salir del mercado basándose únicamente en el ETF SPY. Los resultados en esta etapa demostraron que el agente era capaz de aprender una política defensiva, tendiendo a salir del mercado durante los *drawdowns* severos del histórico de entrenamiento. Sin embargo, la ausencia de fricciones operativas resultó en una política excesivamente conservadora que, si bien protegía el capital, fallaba al capturar de forma óptima los periodos alcistas prolongados. Esta fase fue crítica para confirmar que la estructura de estados propuesta generaba señales interpretables y no ruido estadístico.

La implementación del agente SARSA V1 se fundamenta en el aprendizaje por diferencia temporal (Temporal Difference) de tipo on-policy, lo que significa que el agente actualiza su estimación de valor basándose en la acción real que ejecutará en el siguiente estado, siguiendo su política actual. Técnicamente, esto se materializa mediante una tabla de valores Q (Q-table) de dimensiones mencionadas, donde las filas representan los doce estados discretos derivados de la combinación de tendencia, RSI y posición, y las columnas corresponden a las dos acciones binarias disponibles: mantener la posición actual o cambiarla. La inicialización de esta tabla se realiza con valores nulos, permitiendo que el agente comience su proceso de aprendizaje sin sesgos previos, confiando únicamente en la retroalimentación obtenida a través de la exploración del entorno financiero simulado.

El mecanismo de actualización del conocimiento del agente se rige por la regla clásica de SARSA:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma Q(s', a') - Q(s, a)]$$


En esta ecuación, el error de predicción o error TD se calcula comparando el valor actual de una acción con la suma de la recompensa inmediata recibida y el valor descontado de la siguiente acción en el siguiente estado. Los hiperparámetros juegan un papel crucial en la convergencia; la tasa de aprendizaje determina la velocidad a la que la nueva información sobrescribe el conocimiento previo, mientras que el factor de descuento calibra la importancia que el agente otorga a las recompensas futuras frente a las inmediatas, un factor vital en la inversión donde los resultados suelen observarse a medio plazo.

Para gestionar el dilema entre la explotación de las mejores estrategias conocidas y la exploración de nuevas oportunidades, se ha implementado una política epsilon-greedy. En las fases iniciales del entrenamiento, el valor de épsilon se sitúa en niveles altos para forzar una exploración intensa del mercado; sin embargo, este parámetro decrece progresivamente a lo

largo de los episodios, permitiendo que el agente refine su política y se vuelva más determinista a medida que la tabla Q converge hacia valores estables. Este proceso de entrenamiento iterativo, que recorre el histórico de datos del SPY múltiples veces, permite que el agente asocie configuraciones específicas de indicadores técnicos con la rentabilidad esperada, consolidando finalmente una política que prioriza la supervivencia del capital ante señales de debilidad en la tendencia o niveles críticos de sobrecompra.

Análisis de Resultados


El rendimiento del agente SARSA V1 en el periodo de test revela una ejecución que, aunque técnicamente funcional, exhibe un marcado sesgo conservador ante la dinámica del mercado. Al observar la comparativa en la gráfica de "SARSA vs Mercado", se identifican dos fases críticas que definen la política aprendida;



Durante el tramo bajista inicial del periodo de test, mientras que la estrategia Buy & Hold (curva azul) experimenta un drawdown profundo, el agente SARSA V1 (curva verde) logra mitigar significativamente las pérdidas al identificar señales de riesgo y posicionarse en liquidez (cash). Esta capacidad demuestra que el estado basado en la tendencia (SMA200) y el RSI proporciona una señal de valor real para la supervivencia de la cartera.

El comportamiento posterior del agente es donde se manifiestan sus limitaciones. Tras el tramo bajista, el mercado inicia un rally alcista sostenido; sin embargo, la curva del agente se mantiene prácticamente plana. El análisis de la política mediante el heatmap (mapa de calor) explica esta inacción: el agente aprendió a apostar por rebotes en mercados bajistas.

(comprando en sobreventa), pero mostró una baja confianza para seguir la tendencia en mercados alcistas prolongados, especialmente ante niveles de sobrecompra.



En conclusión, los resultados de SARSA V1 validan que la formulación de aprendizaje por refuerzo es viable, ya que el agente no opera de forma aleatoria, sino que consolida una estrategia defensiva. No obstante, la rentabilidad total termina siendo inferior al *benchmark* debido a una excesiva prudencia y a la falta de matices en el espacio de acciones.

Las limitaciones observadas en la versión uno —especialmente la ausencia de costes de transacción y una visión binaria de la inversión— motivaron el rediseño del entorno hacia un modelo mucho más cercano a un sistema de trading profesional.

5.3 SARSA V2. Hacia el Realismo Operativo

La evolución hacia SARSA V2 introdujo los componentes de realismo necesarios para transformar el prototipo en un sistema de inversión viable. Representa un avance crítico en el rigor de la simulación, migrando de una lógica basada puramente en el precio del activo a una centrada íntegramente en la gestión del valor de la cartera.

El cambio más significativo fue la inclusión de costes de transacción explícitos, fijados en un 0,05% sobre el valor de la cartera por cada operación de compra o venta. Este pequeño ajuste tuvo un impacto drástico en la política aprendida: el agente dejó de realizar operaciones espurias basadas en fluctuaciones menores y comenzó a desarrollar una inercia de inversión más sólida, comprendiendo que entrar y salir del mercado tiene un coste real que debe ser compensado por la rentabilidad esperada. Además, se refinó el espacio de acciones para permitir órdenes explícitas de "mantener", "comprar" o "vender", otorgando mayor control sobre la dinámica de la cartera.

La función de recompensa en SARSA V2 se ha redefinido técnicamente como el retorno simple de la cartera:

$$r_t = \frac{V_{t+1}}{V_t} - 1$$

Al vincular la señal de refuerzo directamente al rendimiento económico de la cartera completa, se logra que los errores de diferencia temporal (TD-errors) tengan una magnitud suficiente para estabilizar y acelerar la convergencia de la política aprendida.


Para blindar al modelo contra el sobreajuste al histórico concreto, la metodología de entrenamiento se modificó hacia un esquema de episodios basados en ventanas temporales aleatorias. En lugar de recorrer la serie temporal siempre de principio a fin, cada episodio de entrenamiento simula una ventana de aproximadamente 252 sesiones (un año bursátil) seleccionada al azar dentro del tramo de datos de entrenamiento. Esta técnica de aleatorización del dominio expone al agente a múltiples regímenes de mercado —alcistas, bajistas y laterales— en un orden no secuencial, forzándolo a generalizar su aprendizaje en lugar de simplemente memorizar la secuencia de precios. Gracias a esta robustez, el agente SARSA V2 logró superar el *Sharpe Ratio* del mercado en el periodo de prueba, demostrando una notable capacidad para gestionar el riesgo de forma autónoma.

Finalmente, la implementación se apoya en un ajuste de hiperparámetros más refinado que en la versión anterior, utilizando una tasa de aprendizaje (alpha) de 0,05 para suavizar las actualizaciones de la tabla Q y un factor de descuento (gamma) de 0,99 que prioriza la

maximización del valor futuro. El proceso garantiza la reproducibilidad científica mediante la fijación de semillas aleatorias globales y específicas para cada episodio del entorno, asegurando que tanto la secuencia de ventanas temporales como la exploración epsilon-greedy sean consistentes entre ejecuciones. Este rigor estructural asegura que las métricas de evaluación obtenidas en el periodo de test, como el ratio de Sharpe o el drawdown máximo, reflejen con precisión la capacidad del modelo para gestionar capital real en condiciones de incertidumbre.

Análisis de Resultados

El análisis de resultados de **SARSA V2** revela una evolución significativa respecto al prototipo inicial, consolidando una política que no solo protege el capital, sino que optimiza el perfil de riesgo-rentabilidad.



Gráficamente y de primera mano, podemos comprender el gran avance que ha supuesto esta versión con respecto al modelo base inicial.

La diferencia más plausible se ubica en la capacidad adaptativa ante los cambios de régimen en el mercado.

Durante la fuerte caída que experimentó el *SPY* en 2022, el agente aprendió a reducir su exposición de forma oportuna con una gestión más proactiva de los activos en la cartera. Mientras que anteriormente la gráfica caía con fuerza, la curva capital de SARSAV2 se mantuvo notablemente más estable, protegiendo el capital mediante el posicionamiento en liquidez.

Por otra parte, al encontrarnos con una tendencia alcista a partir de 2023, el avance crítico respecto a la versión preliminar es que el agente ya no se queda “atrapado” en efectivo. Al

detectar el cambio de tendencia hacia un mercado alcista, el modelo reingresó a posiciones largas, acompañando el rally e incluso superando al benchmark al final de la prueba.

Nota técnica: Recordemos, los modelos SARSA son monoactivo, de ahí el análisis sobre únicamente el SPY y una elección de la estrategia que solo contempla la liquidez sobre la compra.

Los datos extraídos del entorno de simulación confirman la superioridad técnica del agente en términos de eficiencia:

Métrica	Agente SARSA V2	Buy & Hold (SPY)
Rentabilidad Total	41.65%	40.26%
Volatilidad Anualizada	10.94%	17.32%
Sharpe Ratio	1.1794	0.7761
Máximo Drawdown	-10.39%	-22.09%

Optimización del Sharpe Ratio. El agente logró una rentabilidad ligeramente superior a la del mercado, pero lo hizo con una volatilidad drásticamente menor. El incremento del Sharpe Ratio (de 0.77 a 1.17) indica que el agente aprendió a seleccionar sus puntos de entrada con una eficiencia mucho mayor, evitando el ruido del mercado.

Reducción del Riesgo de Cola. La reducción del *drawdown* máximo a menos de la mitad del mercado (-10.39% frente a -22.09%) es el éxito más rotundo de la versión V2. Esto confirma que la inclusión de costes de transacción y el entrenamiento por ventanas aleatorias forzaron al modelo a aprender una política defensiva de alta fidelidad que no comprometiera el crecimiento a largo plazo.

En conclusión, **SARSA V2** valida que un modelo de aprendizaje por refuerzo, incluso con una arquitectura tabular simple, puede batir a una estrategia pasiva cuando el entorno incorpora fricciones realistas y una metodología de entrenamiento robusta. Este resultado proporciona una base de confianza técnica para proceder a la fase de **Deep Q-Network (DQN)**, donde se buscará mantener esta robustez en un entorno multiactivo más complejo

6. Deep Q-Network. Potenciamiento con Redes Neuronales.

6.1. Arquitectura de Deep Reinforcement Learning

La transición de los modelos tabulares SARSA hacia una arquitectura de Deep Reinforcement Learning (DRL) se fundamenta en la necesidad técnica de superar la rigidez de la discretización manual y abordar la naturaleza continua y multidimensional de los mercados financieros modernos. Mientras que las versiones previas colapsaban la realidad del mercado en doce estados estáticos, la implementación de un agente **Deep Q-Network (DQN)** permite procesar un **vector de estado continuo** y denso que sintetiza la complejidad de una cartera multiactivo. Esta capacidad de generalización es crítica para interpretar la interacción no lineal entre activos tan diversos como la renta variable tecnológica (QQQ), los bonos soberanos (TLT) y el oro (GLD), integrando simultáneamente sensores de volatilidad y preferencias dinámicas del usuario.

El vector de estado diseñado para el DQN constituye una representación unificada del entorno en cada paso temporal. Este vector integra cuatro dimensiones fundamentales: datos de mercado (log-rentabilidades y volatilidades móviles de 20 días de los cuatro activos), el estado actual de la cartera (pesos normalizados de efectivo y activos), una memoria de precios medios de compra (ratio entre el precio actual y el de adquisición) y, finalmente, el contexto del usuario. La inclusión de la aversión al riesgo y el horizonte temporal como variables de entrada, aleatorizadas mediante *domain randomization* en cada episodio de entrenamiento, permite que el agente no solo aprenda una política de inversión estática, sino que desarrolle una capacidad de adaptación frente a una distribución completa de perfiles de inversor.

Para aproximar la función de valor $Q(s, a)$ en este espacio de alta dimensión, se ha implementado una red neuronal profunda de tipo Perceptrón Multicapa. La topología de la red consiste en una capa de entrada ajustada a la dimensión del vector de estado, seguida de tres capas ocultas densas con 128, 128 y 64 neuronas, respectivamente, utilizando la función de activación ReLU para introducir no linealidad en el proceso de aprendizaje. Se ha incorporado una capa de Dropout con una tasa del 0.2 tras las capas ocultas como mecanismo de regularización para mitigar el sobreajuste al ruido inherente de los datos financieros. La capa de salida proyecta 9 valores Q correspondientes al espacio de acciones discretizado: una acción de mantenimiento (hold), cuatro órdenes de compra y cuatro órdenes de venta de magnitud fija (10% del valor de la cartera). Esta arquitectura, optimizada mediante el algoritmo Adam con una tasa de aprendizaje de 10^{-3} y una función de pérdida de error

cuadrático medio (MSE), permite al agente discernir patrones sutiles de rentabilidad ajustada al riesgo que serían inalcanzables para una aproximación tabular.

6.2. Estrategias de Estabilización y Entrenamiento

Para mitigar la inestabilidad y asegurar la convergencia del agente *DQN*, se han implementado dos mecanismos fundamentales de estabilización: el **Experience Replay** y la **Target Network**. El uso de un búfer de repetición de experiencias, implementado como una estructura de datos con capacidad para 10,000 transiciones, permite al agente almacenar tuplas de experiencias (s_t, a_t, r_t, s_{t+1}) , y muestrear mini-batches aleatorios de tamaño 64 en cada paso de actualización.

Esta técnica es vital para romper la correlación temporal entre las muestras secuenciales del mercado y asegurar que el gradiente del optimizador se calcule sobre una distribución de experiencias más variada y estable.

Adicionalmente, para solucionar el problema de los "objetivos móviles" en la *ecuación de Bellman*, el agente mantiene dos arquitecturas neuronales distintas: la **policy network**, que se actualiza en cada paso de entrenamiento, y la **Target Network** mencionada, que actúa como una referencia retardada. En nuestra implementación, los pesos de la red de objetivo se sincronizan con los de la red de política cada 10 episodios, lo que proporciona un valor de referencia estable para el cálculo del objetivo TD (*Temporal Difference*) durante las actualizaciones de Q. Este desfase arquitectónico, combinado con un factor de descuento $\gamma = 0.99$, permite que el agente establezca su aprendizaje de largo plazo sin verse afectado por las fluctuaciones bruscas de valor que ocurren durante la optimización de los pesos de la red principal.

La estrategia de entrenamiento se ha configurado sobre 500 episodios, lo que se traduce en aproximadamente 120,000 pasos de interacción con el entorno multiactivo. Cada episodio simula una ventana de 252 sesiones bursátiles (1 año) con puntos de inicio aleatorios, forzando al modelo a aprender patrones transversales a diferentes ciclos económicos. Para gestionar el compromiso entre exploración y explotación, se ha desplegado una política *epsilon-greedy* con un decaimiento multiplicativo que comienza en exploración pura ($\epsilon = 1.0$) y se reduce hasta un umbral mínimo de 0.01. Es relevante destacar que, dado que el decaimiento se aplica por cada paso de entrenamiento, el agente alcanza su fase de explotación casi determinista en torno al episodio 40, permitiendo una extensa fase de refinamiento de la política sobre el 90% restante del entrenamiento.

6.3. Función de Recompensa

El núcleo de la personalización en el agente *DQN* reside en el diseño de su función de recompensa, la cual trasciende la simple maximización del beneficio para convertirse en un modelo de optimización multiobjetivo ajustado al riesgo. A diferencia de los modelos *SARSA* previos, donde la recompensa era el retorno simple de la cartera, el *DQN* integra la aversión al riesgo del usuario como un componente penalizador directo en la señal de aprendizaje, lo que ha sido un punto central de nuestra hipótesis desde el primer planteamiento del proyecto.

La idea final representa un avance cualitativo respecto a los modelos previos, al transitar de una métrica de retorno absoluto hacia una optimización basada en el **exceso de rentabilidad relativa o "alpha"**. En esta configuración, el objetivo primordial del agente no es simplemente el crecimiento del capital, sino la capacidad de batir sistemáticamente al benchmark de referencia, el *ETF SPY (S&P 500)*.

Técnicamente, la recompensa bruta en cada paso temporal se articula mediante la siguiente lógica de cálculo:

$$\text{reward_raw}_t = (r_{\text{diario},t} - r_{\text{spy},t}) - \text{risk_penalty}_t$$

Esta formulación es de vital importancia para el aprendizaje, ya que desvincula la señal de refuerzo de la tendencia general del mercado; el agente recibe un estímulo positivo únicamente si su decisión de inversión —ya sea por sobreponderación de activos con momentum o por una gestión defensiva superior— logra superar el rendimiento del benchmark, una vez descontada la penalización por riesgo asociado. La penalización por riesgo continúa actuando como un regulador dinámico que alinea la política del agente con la aversión al riesgo específica del usuario, penalizando la volatilidad excesiva en función del perfil entrenado

$$\text{reward}_t = \text{clip}(100 \cdot \text{reward_raw}_t, -10, 10)$$

Para asegurar la estabilidad del proceso de entrenamiento en un entorno con recompensas financieras intrínsecamente ruidosas, se han aplicado técnicas de normalización y acotamiento de gradientes. Específicamente, se ha implementado un clipping de la recompensa en un rango estricto de $[-10, 10]$. Esta medida de ingeniería es fundamental para evitar el fenómeno de gradientes explosivos que podría ocurrir tras movimientos bruscos de mercado o picos de volatilidad, los cuales generarían valores de recompensa extremos capaces de desestabilizar los pesos de la red neuronal. Asimismo, el escalado por un factor de 100 permite que la

magnitud de la señal de refuerzo sea lo suficientemente significativa para que el optimizador Adam identifique con claridad la dirección de mejora en la política, facilitando así la convergencia hacia una estrategia de inversión que respete de forma consistente las restricciones de riesgo impuestas por el perfil del usuario.

6.4. Análisis de Resultados y Discusión


Metodología de Evaluación y Rigor de las Pruebas

La validación del agente Deep Q-Network (DQN) se ha fundamentado en una metodología de *backtesting* estrictamente secuencial y fuera de la muestra (*out-of-sample*), utilizando un desglose temporal de 80/20. El periodo de testeo, comprendido entre 2022 y finales de 2024, ha sido seleccionado deliberadamente para evaluar la capacidad de generalización del modelo ante un régimen de mercado radicalmente distinto al del tramo de entrenamiento (2010-2021), caracterizado por una inflación persistente y un ciclo de endurecimiento monetario. El uso de la estrategia *Buy & Hold* sobre el SPY como *benchmark* no es casual; representa el estándar de eficiencia pasiva que cualquier gestión activa, incluso una basada en inteligencia artificial, debe ser capaz de superar para justificar su complejidad operativa. Esta estructura de pruebas busca aislar el rendimiento real del agente, evitando sesgos de supervivencia o de anticipación de datos.

Comportamiento y Diferenciación por Perfiles de Usuario.


Gracias a la implementación de la aleatorización del dominio (*domain randomization*) durante el entrenamiento, el agente ha sido expuesto a una distribución continua de preferencias, permitiéndonos identificar tres comportamientos arquetípicos claramente diferenciados durante la fase de ejecución y que nos permitirán testear el algoritmo con naturalezas muy diferentes en su estrategia de inversión.

A) Perfil Agresión (Aversión al Riesgo -> 0): En este escenario, la función de recompensa ignora prácticamente la volatilidad, centrando el aprendizaje en la captura del retorno absoluto. Técnicamente, el agente muestra una mayor propensión a mantener pesos




elevados en activos como el *QQQ* y el *TLT*, asumiendo una exposición máxima al mercado incluso en períodos de incertidumbre.

El resultado es una curva de capital con una pendiente de crecimiento potencial más alta, pero vulnerable a correcciones profundas del mercado y cambios bruscos en el mercado (que aunque no comunes, si bastante posibles como analizamos en la *sección 4*).




Seguramente, la apreciación más notoria que podemos realizar acerca de este perfilado de estrategia de inversión sea la cantidad de liquidez que mantiene durante las pruebas.



Y es que no debemos dejar pasar el detalle más revelador acerca de cómo ha ajustado el modelo las características de usuario personalizadas; Ha asociado a un usuario agresivo con alguien que emplea todo el valor de su cartera en seguir invirtiendo, alejándose del cash.

B) Perfil Moderado o Neutral (Aversión al Riesgo $\rightarrow 0'5$): Para capturar los distintos rangos posibles en términos de usuario y decisiones, introducimos un perfil que representa el equilibrio técnico donde el factor de escala λ pondere de forma equitativa el crecimiento y la estabilidad.




En este sentido, el agente tiende a realizar rebalanceos más frecuentes, rotando capital entre renta variable y activos de cobertura (*TLT*) cuando las señales de volatilidad del mercado superan el umbral de penalización, sobretudo al inicio del test.


Observando el valor de su cartera, podemos apreciar también como es el perfil que mejor demuestra la capacidad del *DQN* para procesar el vector de estado multiactivo.




En términos de liquidez, un perfil intermedio también parece centrarse en mantener los niveles de cash bajos.




C) Perfil Conservador (Aversión al Riesgo -> 1): Finalmente, en la prueba actual, la aversión al riesgo actúa como una restricción severa, donde cualquier incremento en el *proxy* de volatilidad de la cartera reduce drásticamente la recompensa neta. La política aprendida por el agente en este perfil se caracteriza por una huida hacia la seguridad, refugiándose en *TLT*, lo que confirma nuestras conclusiones del Análisis Exploratorio de Datos inicial.



La diferencia fundamental con los perfiles anteriores radica en su capacidad para estabilizar el valor de la cartera a costa de no participar plenamente en los rallies alcistas, como muy claramente se puede apreciar en la siguiente gráfica:



De la misma manera que hemos apreciado la animadversión de los perfiles con menor aversión al riesgo a la liquidez, es interesante comprobar si esta tendencia se mantiene para lo ejecutado con un perfil de usuario de distintas características.



Como podemos observar y en concordancia con lo observado en la anterior gráfica sobre su rechazo a la unión de los rallies alcistas, nos encontramos con que el modelo ha elegido una estrategia diferente, pues su disponibilidad en liquidez es muy superior, garantizando una mayor seguridad.

Justificación de Resultados y Comparativa Final

Tras completar la fase de evaluación de ambas arquitecturas, nos enfrentamos a una aparente paradoja de ingeniería: el agente *DQN*, a pesar de integrar una arquitectura de red profunda mucho más potente y operar en un entorno multiactivo más realista, no ha logrado superar el rendimiento del benchmark *buy & hold* en el periodo de test. Por el contrario, el agente *SARSA V2*, basado en una aproximación tabular significativamente más sencilla y limitada a un solo activo, ha demostrado una robustez superior, llegando a mejorar ligeramente los resultados del mercado.

Este fenómeno no es una anomalía, sino un resultado altamente informativo que subraya los desafíos críticos de la aplicación de RL en finanzas que hemos encontrado y experimentado:

1. **Complejidad del Espacio de Estados y Acción:** El agente *DQN* se ve forzado a aprender en un espacio de estados continuo de alta dimensión que integra rendimientos, volatilidades, pesos de cartera y variables de usuario. Esta densidad informativa, sumada a un espacio de acciones amplio para el rebalanceo de cuatro activos, introduce una dificultad de convergencia exponencial en comparación con los doce estados discretos de *SARSA V2*. La estabilidad de la política en *DQN* se ve comprometida por

esta amplitud de búsqueda, requiriendo posiblemente un volumen de episodios de entrenamiento muy superior al ejecutado.

2. **Inestabilidad de la Función Objetivo:** La señal de recompensa en el modelo *DQN* es intrínsecamente ruidosa y no estacionaria. Al mezclar el retorno financiero con una penalización por volatilidad modulada aleatoriamente por la aversión al riesgo del usuario en cada episodio, el agente se enfrenta a un objetivo cambiante que dificulta la optimización del gradiente. *SARSAV2*, al operar bajo una función de recompensa más directa y un entorno más restringido, logra una convergencia más limpia hacia una política defensiva efectiva.
3. **Desplazamiento de Régimen y Sobreajuste:** La red neuronal del *DQN* posee la capacidad de ajustar patrones muy específicos del histórico de entrenamiento (2010–2021). Sin embargo, el periodo de test (2022–2024) ha estado marcado por un cambio de régimen macroeconómico radical: inflación elevada y subidas de tipos de interés, que no se manifestó en la década previa. Mientras que *SARSAV2* mantiene una política genérica basada en tendencia y momento que se adapta bien a la incertidumbre, el *DQN* parece haber "memorizado" un mercado alcista que ya no existe, resultando en una política excesivamente conservadora que prioriza bonos y efectivo, perdiendo así la participación en el rally de renta variable posterior.

7. Conclusiones y Vías Futuras

Los resultados de este proyecto refuerzan una premisa fundamental en la arquitectura de sistemas: en entornos de datos limitados y alta varianza como los mercados financieros, **un modelo simple bien ajustado a un entorno concreto suele ser más efectivo que un modelo complejo en un entorno general**. La robustez demostrada por **SARSAV2** frente a la divergencia del **DQN** resalta la importancia de la simplicidad estructural cuando se enfrenta a la naturaleza impredecible de los cambios de régimen económico.

De forma general, ha permitido validar la viabilidad del Aprendizaje por Refuerzo (RL) como una herramienta capaz de sintetizar políticas de inversión coherentes a partir de la observación de datos históricos. A través de un desarrollo incremental, se ha demostrado que es posible modelar el mercado financiero como un entorno interactivo donde un agente aprende a balancear la rentabilidad y el riesgo. El hallazgo más significativo de esta investigación es la disparidad entre la potencia teórica de los modelos y su eficacia práctica en entornos no estacionarios. Mientras que el agente **SARSAV2**, basado en una arquitectura tabular sencilla y un espacio de estados restringido, logró batir al *benchmark* mediante una estrategia defensiva robusta que minimizó el *drawdown* en periodos críticos, el modelo **DQN**, a pesar de su sofisticación neuronal, se vio penalizado por la alta dimensionalidad y el ruido intrínseco de los mercados.

En última instancia, los resultados refuerzan una premisa fundamental en la ingeniería de sistemas aplicados a finanzas: la robustez suele derivar de la simplicidad estructural. El agente **DQN**, al intentar procesar un vector de estado denso en un mercado que sufrió cambios de régimen drásticos entre el entrenamiento y el test, desarrolló un sesgo excesivamente conservador que le impidió capitalizar los rallies alcistas posteriores. No obstante, el éxito de **SARSAV2** confirma que las señales técnicas discretizadas como la tendencia y el *RSI* contienen valor predictivo suficiente para gestionar el capital de forma más eficiente que una estrategia pasiva bajo condiciones de alta volatilidad.

7.1. Vías Futuras: Integración de Sensores y NLP

Una de las líneas de expansión más prometedoras para este sistema reside en la incorporación efectiva de los "sensores de entorno" identificados durante la fase de análisis exploratorio (EDA). Indicadores macroeconómicos como el **índice de volatilidad (^VIX)**, la **tasa de bonos a 10 años (^TNX)**, el **petróleo crudo (CL=F)** y el **índice dólar (DX-Y.F)** fueron cargados inicialmente por su capacidad para contextualizar la salud global del mercado, aunque no se

utilizaron en los modelos finales para evitar una complejidad computacional inmanejable en esta etapa.

La integración futura de estos sensores podría realizarse mediante una rama especializada de **Procesamiento de Lenguaje Natural (NLP)**. Esta arquitectura permitiría fusionar los datos numéricos de los sensores con el análisis de sentimiento extraído de noticias financieras, informes de la Reserva Federal o indicadores de incertidumbre económica. Al procesar esta información, el agente obtendría un conocimiento profundo sobre el entorno macroeconómico, entendiendo, por ejemplo, cómo una subida en el $^{\wedge}TNX$ o una fluctuación en el petróleo precede a cambios de régimen en la renta variable, sin necesidad de operar directamente con estos activos.

Esta rama de *NLP* actuaría como un "extractor de contexto" que enriquecería el vector de estado del *DQN*, permitiendo al modelo anticipar periodos de estrés antes de que se reflejen puramente en el precio. De este modo, el sistema evolucionaría de un modelo basado en la reactividad técnica a uno de **conciencia situacional**, capaz de ajustar su política de riesgo basándose en la narrativa económica global. Esta integración no solo mejoraría la generalización del agente ante eventos de distinta naturaleza, sino que resolvería la tendencia al sobreajuste detectada, dotando a la inteligencia artificial de una visión macroscópica esencial para la inversión profesional a largo plazo.

Propuesta Técnica

Una propuesta técnica para la implementación de esta arquitectura de **Procesamiento de Lenguaje Natural (NLP)** se basaría en la creación de un módulo "Extractor de Contexto" que opere en paralelo a la red neuronal del agente.

La idea principal consiste en utilizar un modelo de lenguaje pre-entrenado y especializado en el dominio financiero, como **FinBERT**, para procesar flujos de texto provenientes de informes de la Reserva Federal, minutas de reuniones de tipos de interés y titulares de prensa económica. Este módulo transformaría el texto no estructurado en un **vector de sentimiento o vector macroeconómico** de baja dimensionalidad. Dicho vector se concatenaría al vector de estado actual del *DQN* (que ya incluye precios y volatilidades), proporcionando al agente una señal predictiva sobre la dirección del mercado antes de que los cambios se reflejen completamente en las series temporales de precios.

Para elevar el nivel de sofisticación del sistema, se podría profundizar en la arquitectura mediante la implementación de un **pipeline de ingesta en tiempo real**. Esto implicaría el uso de tecnologías de mensajería o *streaming* para capturar noticias de última hora de forma instantánea. Al integrar esta ingesta continua, el modelo no solo analizaría datos históricos, sino que desarrollaría una **conciencia situacional inmediata**. Esto permitiría al agente reaccionar de manera proactiva ante eventos geopolíticos o anuncios macroeconómicos inesperados, ajustando dinámicamente los pesos de la cartera y la exposición al riesgo (basándose en los sensores VIX, TNX, CL=F y DX-Y.F) en milisegundos tras la publicación de la información.

8. Bibliografía

- Araci, D. (2019).** *FinBERT: Financial Sentiment Analysis with Pre-trained Language Models*. arXiv preprint arXiv:1908.10063.
- Dixon, M. F., Halperin, I., & Bilokon, P. (2020).** *Machine Learning in Finance: From Theory to Practice*. Springer.
- Farama Foundation. (2022).** *Gymnasium: An Open Source Interface for Reinforcement Learning Task Environments*. <https://gymnasium.farama.org/>.
- Forsyth, L. (2025).** *Dynamic Portfolio Management through Deep Q-Network-Based Asset Allocation*. Journal of Computer Science and Software Applications.
- Kingma, D. P., & Ba, J. (2014).** *Adam: A Method for Stochastic Optimization*. arXiv preprint arXiv:1412.6980.
- Li, Y., et al. (2025).** *Reinforcement Learning for Financial Portfolio Optimization: Dynamic Strategies for Risk and Reward Management*.
- Markowitz, H. (1952).** *Portfolio Selection*. The Journal of Finance, 7(1), 77-91.
- Mnih, V., et al. (2015).** *Human-level control through deep reinforcement learning*. Nature, 518(7540), 529-533.
- Park, H., et al. (2020).** *An intelligent financial portfolio trading strategy using deep Q-learning*. Expert Systems with Applications.
- Sutton, R. S., & Barto, A. G. (2018).** *Reinforcement Learning: An Introduction*. MIT Press.
- Zhang, Z., et al. (2025).** *Development of a Multi-Objective Optimisation Framework for Risk-Aware Fractional Investment Using Reinforcement Learning*.
- Juan Antonio Botía (2025).** Apuntes de la asignatura de *Extensiones de Machine Learning* en el contexto del Grado en Ciencia e Ingeniería de Datos. Universidad de Murcia.